

RAPPORT 1 — Classification Binaire avec MLP : Impact des Stratégies d'Initialisation

Projet : Deep Learning — Partie 1 Date : Juin 2026

1. Introduction et Objectifs

Ce rapport présente l'implémentation d'un **Perceptron Multi-Couches (MLP)** appliqué à la classification binaire du dataset **Breast Cancer Wisconsin**. L'objectif principal est d'étudier l'influence critique de **l'initialisation des poids** sur la convergence et les performances finales du modèle.

Problématique : Pourquoi deux réseaux identiques en architecture peuvent-ils converger vers des performances radicalement différentes selon la façon dont leurs poids sont initialisés ?

2. Méthodologie

2.1 Dataset

Caractéristique	Valeur
Source	<code>sklearn.datasets.load_breast_cancer</code>
Nombre d'échantillons	569
Nombre de features	30 (caractéristiques morphologiques)
Classes	0 (maligne) / 1 (bénigne)
Séparation	70% train / 15% val / 15% test (stratifiée)

2.2 Prétraitement

- **Normalisation** : `StandardScaler` appliqué sur le train set uniquement (pour éviter le data leakage).
- **Conversion** : Tenseurs PyTorch `float32`, targets reshapées en `(N, 1)`.
- **DataLoaders** : `batch_size = 32`, shuffle activé sur le train set.

2.3 Architecture du Modèle

Input (30) → Linear(64) → ReLU → Linear(32) → ReLU → Linear(1) → BCEWithLogitsLoss

Choix justifiés :

- **BCEWithLogitsLoss** : combine sigmoid + BCE en une opération numériquement stable.
- **Adam optimizer** : $lr = 1e-3$, convergence rapide.
- **50 epochs** : durée suffisante pour observer distinctement les dynamiques de convergence.

2.4 Stratégies d'Initialisation Testées

Stratégie	Poids	Biais
Gaussian	<code>normal(mean=0, std=0.01)</code>	<code>constant(0)</code>
Constant	<code>constant(0.01)</code>	<code>constant(0)</code>
Xavier	<code>xavier_uniform_</code>	<code>zeros_</code>

3. Résultats Expérimentaux

3.1 Courbes d'Apprentissage

Les courbes de loss et d'accuracy sur les ensembles train/validation mettent en évidence des comportements distincts :

- **Gaussian** : convergence très rapide et stable dès les premières epochs.
- **Xavier** : convergence légèrement plus lente mais hautement stable à terme.
- **Constant** : convergence irrégulière, forte sensibilité aux minima locaux due à la symétrie initiale.

3.2 Performance sur le Test Set (Meilleur modèle : Gaussian)

Métrique	Valeur	Interprétation
Accuracy	91.86%	Taux de classification correcte global élevé.
Precision	92.73%	Faible taux de faux positifs (sécurité du diagnostic).
Recall	94.44%	Excellente détection des cas réels.
F1-Score	93.58%	Équilibre optimal entre précision et recall.

3.3 Validation Accuracy par Initialisation

Initialisation	Val Accuracy
Gaussian	98.82% 
Xavier	Variable / Instable sur ce faible nombre de couches
Constant	Variable et globalement inférieure

4. Analyse et Discussion

4.1 Pourquoi Gaussian surpasse Xavier ici ?

Bien que **Xavier** soit théoriquement optimal pour les réseaux profonds (car il préserve la variance des activations à travers les couches), notre MLP est ici **peu profond** (seulement 2 couches cachées). Sur un problème linéaire simple avec peu de non-linéarités :

- Une initialisation **très petite** ($\text{std}=0.01$) place d'emblée le réseau dans une région stable et "douce" de la loss landscape.
- Les gradients restent stables, évitant les phénomènes d'explosion ou de saturation précoce.
- Xavier, en initialisant avec des valeurs proportionnellement plus grandes, peut induire des instabilités temporaires sur de petites architectures.

4.2 Importance de la Normalisation

Sans l'utilisation du `StandardScaler`, les caractéristiques (features) à grande échelle domineraient mathématiquement les gradients, rendant le choix de l'initialisation encore plus critique et risqué. La normalisation **réduit la sensibilité globale** au choix d'initialisation sans toutefois l'éliminer.

4.3 Matrice de Confusion

L'analyse approfondie de la matrice de confusion révèle une excellente détection des cas critiques (Recall de 94.44%), avec un nombre très limité de faux négatifs, ce qui s'avère absolument crucial dans le cadre d'un diagnostic médical assisté par ordinateur.

5. Conclusion

Cette étude démontre de manière empirique que **l'initialisation des poids n'est pas un simple détail technique**, mais constitue un hyperparamètre fondamental de l'architecture des réseaux de neurones. Les enseignements clés sont les suivants :

1. **Gaussian (std=0.01)** obtient les meilleures performances sur ce dataset simple et peu profond.
2. **Xavier** demeure la référence incontournable pour les configurations réseaux profonds.
3. **Constant** met en exergue les limites évidentes d'une initialisation naïve brisant difficilement la symétrie.
4. La **reproductibilité** de l'expérience est pleinement assurée par le gel des seeds aléatoires et la séparation stratifiée.

Perspectives : Étendre cette suite d'expériences à des architectures nettement plus profondes où Xavier et He initialization affirmeront leur supériorité théorique.

6. Références

- Glorot & Bengio (2010). *Understanding the difficulty of training deep feedforward neural networks*
- He et al. (2015). *Delving Deep into Rectifiers: Surpassing Human-Level Performance*
- Documentation PyTorch : `torch.nn.init`